TRABAJO FINAL · ANÁLISIS DE DATOS

Conclusiones del trabajo

1. Conclusiones del análisis exploratorio de datos

El análisis exploratorio del dataset sintético de fermentación etanólica industrial permitió identificar patrones y asociaciones entre variables microbiológicas, operativas y productivas del proceso.

Entre los principales resultados se destacan:

- **Contaminación bacteriana y viabilidad de levaduras:** se identificó una correlación negativa moderada (r = −0,55), indicando que los mayores niveles de contaminación tienden a asociarse con menores porcentajes de viabilidad celular. Esta relación se mantuvo al analizar individualmente distintas destilerías, aunque con variaciones en su intensidad.
- **Comparación de tratamientos de control bacteriano:** los registros correspondientes al tratamiento con antibiótico presentaron los menores valores promedio y medianas de contaminación bacteriana, seguidos por el biocida comercial y el extracto vegetal experimental. El grupo sin tratamiento presentó los niveles más elevados. Los diagramas de cajas permitieron observar, además, la dispersión de los datos y la presencia de valores atípicos en todos los grupos.
- **Concentración inicial de azúcares y producción de etanol:** se observó una correlación positiva (r = 0,66), indicando que los mostos con mayor °Brix inicial tienden a presentar mayores concentraciones finales de etanol. Esta asociación también se identificó al analizar diferentes plantas y sustratos.
- **Temperatura y rendimiento fermentativo:** se encontró una correlación negativa muy débil (r = −0,11), por lo que no se identificó una asociación lineal importante entre estas variables en el conjunto de datos analizado.
- **Viabilidad y rendimiento fermentativo:** se observó una correlación positiva (r = 0,62), mostrando que los registros con mayor viabilidad de levaduras tienden a presentar mejores rendimientos fermentativos.
- **Distribución y evolución temporal del rendimiento:** los valores de rendimiento se concentraron principalmente entre el 80 y el 90 %, con menor frecuencia de registros de bajo rendimiento. La evolución temporal mostró fluctuaciones y una ligera tendencia descendente, sin que sea posible establecer sus causas a partir de los datos disponibles.

El mapa de calor permitió complementar estos resultados, destacándose también la correlación negativa entre los azúcares residuales y el rendimiento fermentativo (r = −0,79), así como la asociación positiva entre contaminación bacteriana y azúcares residuales (r = 0,73).

2. Conclusiones sobre el proceso de aprendizaje y las herramientas utilizadas

El desarrollo del proyecto permitió aplicar de manera integrada distintas herramientas y procedimientos de análisis de datos, desde la preparación inicial del dataset hasta la comunicación visual de los resultados.

Durante la etapa de limpieza, realizada en Python mediante Google Colab, se trabajó en la normalización de variables, identificación de registros duplicados, tratamiento de valores faltantes, detección de datos fuera de rango e imputación de valores mediante criterios de agrupación. Como resultado, se obtuvo un conjunto de 5.792 registros a partir de los 6.000 originales.

La exploración posterior también permitió identificar algunas anomalías que no habían sido detectadas inicialmente, poniendo de manifiesto la importancia de complementar la limpieza con el análisis gráfico y la revisión crítica de los datos.

Las bibliotecas Matplotlib, Seaborn y Plotly facilitaron la construcción de gráficos estadísticos y la exploración de relaciones entre variables. Por su parte, Power BI permitió integrar los principales resultados en dos dashboards interactivos, incorporando indicadores, líneas de tendencia, coeficientes de correlación y filtros por destilería, sustrato y tratamiento.

En conjunto, el trabajo permitió comprender la importancia de la calidad de los datos, la selección adecuada de herramientas estadísticas y la visualización interactiva para explorar e interpretar información.

Finalmente, dado que se utilizó un dataset sintético generado con fines didácticos, los resultados deben interpretarse como parte de un ejercicio de análisis exploratorio y no como evidencia experimental aplicable directamente a procesos industriales reales.